

Backpropagation

Gradient Descent (batch)

1. Inicialize a Rede Neural com pesos aleatórios
2. Para cada instancia dos dados x_i (i-ésima linha) da matriz X
 - (a) Faça o Fordward Pass, ou seja, calcule a ativação de cada neurônio da rede, ou seja, calcule o valor final que cada neurônio possuirá (por exemplo para a camada L devemos ter $a_1^{(L)}, a_2^{(L)}, \dots, a_n^{(L)}$ onde:

$$a_i^{(L)} = \sigma(z_i^{(L)}),$$

$$z_i^{(L)} = w_{i0}^{(L-1)} a_0^{(L-1)} + w_{i1}^{(L-1)} a_1^{(L-1)} + \dots + w_{im}^{(L-1)} a_m^{(L-1)} \text{ e}$$

$$a_0^{(L)} = 1 \text{ (é o bias)}$$

- (b) Calcule δ para todos os Neurônios na Output Layer, usando a predição (ou seja a saída final dada pela output layer) e o target. Ambos (predição e target), no caso de uma única saída para cada instancia, serão um vetor ou, uma matriz caso haja múltiplas saídas para cada instancia:

$$\delta_j^{(L)} = 2 \left(\hat{a}_j^{(L)} - a_j^{(L)} \right) a_j^{(L)} (1 - a_j^{(L)})$$

- (c) Calcule δ para todos os Neurônios nas camadas anteriores:

$$\delta_j^{(L)} = \sum_k \delta_k^{(L+1)} w_{kj}^{(L+1)} a_j^{(L)} (1 - a_j^{(L)})$$

- (d) Calcule o Gradiente da Função de Erro em relação a todos os pesos $w_{jk}^L, k \neq 0$ e w_{j0}^L (bias da camada L). (Pode ser utilizada apenas a formula da esquerda tomando $a_0^{L-1} = 1$)

$$\frac{\partial E_{x_i}}{\partial w_{jk}^{(L)}} = \delta_j^{(L)} a_k^{(L-1)} \quad \frac{\partial E_{x_i}}{\partial w_{j0}^{(L)}} = \delta_j^{(L)}$$

3. Calcule a media do Gradiente em relação a cada Peso e a cada Bias sobre todo o Conjunto de Treinamento (Pode ser utilizada a formula unificada):

$$\frac{\partial E}{\partial w_{jk}^{(L)}} = \frac{1}{n} \sum \frac{\partial E_{x_i}}{\partial w_{jk}^{(L)}} \quad \frac{\partial E}{\partial w_{j0}^{(L)}} = \frac{1}{n} \sum \frac{\partial E_{x_i}}{\partial w_{j0}^{(L)}}$$

4. Atualize os Pesos e os Bias usando Gradient Descent (novamente, isso pode ser feito tudo junto, apenas com a formula da esquerda):

$$w_{jk}^{(L)} \rightarrow w_{jk}^{(L)} = w_{jk}^{(L)} - \eta \frac{\partial E}{\partial w_{jk}^{(L)}} \quad w_{j0}^{(L)} \rightarrow w_{j0}^{(L)} = w_{j0}^{(L)} - \eta \frac{\partial E}{\partial w_{j0}^{(L)}}$$

5. Repita os passos 2-4 ate que o Erro reduza a um nível aceitável, cada uma destas repetições dos passos 2 ate 4 é chamada de Epoch, ou seja, uma Epoch é fazer os passos 2, 3 e 4

Stochastic Gradient Descent

1. Inicialize a Rede Neural com pesos aleatórios
2. Para cada instancia dos dados x_i (i-ésima linha) da matriz X

- (a) Faça o Forward Pass, ou seja, calcule a ativação de cada neurônio da rede, ou seja, calcule o valor final que cada neurônio possuirá (por exemplo para a camada L devemos ter $a_1^{(L)}, a_2^{(L)}, \dots, a_n^{(L)}$ onde:

$$a_i^{(L)} = \sigma(z_i^{(L)}),$$

$$z_i^{(L)} = w_{i0}^{(L-1)} a_0^{(L-1)} + w_{i1}^{(L-1)} a_1^{(L-1)} + \dots + w_{im}^{(L-1)} a_m^{(L-1)} \text{ e}$$

$$a_0^{(L)} = 1 \text{ (é o bias)}$$

- (b) Calcule δ para todos os Neurônios na Output Layer, usando a predição (ou seja a saída final dada pela output layer) e o target. Ambos (predição e target), no caso de uma única saída para cada instancia, serão um vetor ou, uma matriz caso haja múltiplas saídas para cada instancia:

$$\delta_j^{(L)} = 2 \left(\hat{a}_j^{(L)} - a_j^{(L)} \right) a_j^{(L)} (1 - a_j^{(L)})$$

- (c) Calcule δ para todos os Neurônios nas camadas anteriores:

$$\delta_j^{(L)} = \sum_k \delta_k^{(L+1)} w_{kj}^{(L+1)} a_j^{(L)} (1 - a_j^{(L)})$$

- (d) Calcule o Gradiente da Função de Erro em relação a todos os pesos w_{jk}^L , $k \neq 0$ e w_{j0}^L (bias da camada L). (Pode ser utilizada apenas a formula da esquerda tomando $a_0^{L-1} = 1$)

$$\frac{\partial E_{x_i}}{\partial w_{jk}^{(L)}} = \delta_j^{(L)} a_k^{(L-1)} \quad \frac{\partial E_{x_i}}{\partial w_{j0}^{(L)}} = \delta_j^{(L)}$$

- (e) Atualize os Pesos e os Bias usando Stochastic Gradient Descent (novamente, isso pode ser feito tudo junto, apenas com a formula da esquerda):

$$w_{jk}^{(L)} \rightarrow w_{jk}^{(L)} = w_{jk}^{(L)} - \eta \frac{\partial E_{x_i}}{\partial w_{jk}^{(L)}} \quad w_{j0}^{(L)} \rightarrow w_{j0}^{(L)} = w_{j0}^{(L)} - \eta \frac{\partial E_{x_i}}{\partial w_{j0}^{(L)}}$$

3. Repita os passos 2 ate que o Erro reduza a um nível aceitável, cada uma das repetições do passo 2 é chamada de Epoch, ou seja, uma Epoch é fazer o passo 2 inteiro