

Técnicas e Algoritmos em Ciência de Dados

Tarefa 1

Este trabalho deve ser entregue até **18 de março de 2026, às 9:00 da manhã**.
As submissões tardias serão **penalizadas em 10% por hora de atraso**.

Tópicos de aprendizagem avaliados

Esta tarefa testará alguns conceitos básicos de Ciência de Dados e programação Python para análise de dados (Pandas, Seaborn). Especificamente, carregamento de dados, visualizações simples e avaliação de modelos de classificação e regressão pré-treinados.

Instruções

Identificação

Por favor, escolha um número aleatório de 6 dígitos e escreva-o na primeira célula do notebook. Certifique-se de manter uma cópia desse número, pois ele será usado para fornecer o feedback (por favor, evite números triviais, como 000000 ou 123456 – obrigado).

OBS: VOCÊ USARÁ ESTE IDENTIFICADOR PARA TODAS AS TAREFAS.
--

Submissão

Envie seus arquivos pelo ECLASS. Os arquivos que você envia não podem ser lidos por nenhum outro aluno. Você pode substituir seu envio quantas vezes quiser, reenviando-o, embora apenas a última versão enviada seja mantida.

Se você tiver problemas, no último minuto, envie sua tarefa por e-mail como um anexo para alberto.paccanaro@fgv.br com o assunto "URGENTE – SUBMISSÃO TAREFA 1". No corpo da mensagem, explique o motivo de não enviar através do ECLASS.

IMPORTANTE

- Seu envio consistirá em um único bloco de anotações Python implementando suas soluções.
- **O nome do arquivo será o número aleatório que o identifica (por exemplo, 568423.ipynb)**
- Esta tarefa contém 3 partes. Certifique-se de que o seu código para todas as 3 partes é colocado nas células de código correspondentes no notebook.
- **NÃO ENVIE NENHUM CONJUNTO DE DADOS**, apenas o código.
- Qualquer função auxiliar que você utilizar deve ser incluída no notebook – não envie scripts adicionais.
- *Não usar ferramentas de IA como ChatGPT, Copilot, Gemini, etc. Este trabalho foi elaborado para que você se familiarize com conceitos importantes que só podem ser aprendidos por meio da experiência prática.*

Todo o trabalho que você enviar deve ser exclusivamente seu próprio trabalho. As submissões serão verificadas para isso.

Caso seja suspeitada alguma atividade irregular nas tarefas (por exemplo, plágio, uso de IA etc.), os laboratórios serão também avaliados e, para cada laboratório considerado inadequado, o aluno perderá o ponto correspondente.

Critérios de avaliação

Esta atividade é obrigatória e vale **6%** da sua nota final total para este curso. Para obter notas máximas para cada pergunta, você deve respondê-la corretamente, mas também completamente. Notas serão dadas por escrever códigos bem estruturados.

EXERCÍCIOS

Parte 1 – Carregamento e Visualização de Dados – valor desta seção: 20%

Baixe do repositório <https://github.com/Mbaez97/fgv-class-2026-tarefa-1.git>

- diamonds.csv (dados sobre diamantes – descrição das features estão disponível aqui: <https://ggplot2.tidyverse.org/reference/diamonds.html>)
- T1_template.ipynb

Aqui estão as etapas que você precisará implementar:

- Carregar os dados em um DataFrame pandas
- Limpeza do conjunto de dados, removendo pontos de dados com valores ausentes e duplicados
- Para cada feature do conjunto de dados, faça uma figura contendo 2 subgráficos (subplots) mostrando:
 - O histograma dos valores da feature (todas as classes combinadas)
 - O histograma dos valores da feature, separadamente para cada classe, utilizando a coluna “cut” como identificador de classe. Use uma cor diferente para cada classe.

Observe que todos os histogramas devem ter 50 bins e ser normalizados (isto é, a área sob o histograma deve ser igual a 1).

Para cada feature, a figura deve ser como a Figura 1.




Figura 1

Baixe do repositório 2 files (<https://github.com/Mbaez97/fgv-class-2026-tarefa-1.git>)

- classifiers_dict.p
- bank_marketing_test_data.p

Os dados estão relacionados a campanhas de marketing direto (ligações telefônicas) de uma instituição bancária portuguesa. Esses dados foram usados para treinar sistemas de classificação para prever se um cliente irá subscrever um depósito a prazo (variável y).

O primeiro contém três classificadores pré-treinados e o segundo é o conjunto de dados de teste. O objetivo deste exercício é avaliar o desempenho dos modelos de classificação pré-treinados na predição de se uma pessoa irá subscrever o depósito bancário.

Para isso, geraremos curvas de “Precision–Recall” (PR) para cada algoritmo e determinaremos a área sob a curva. Usando essa métrica, decidiremos qual classificador é mais adequado para a tarefa. Observe que você precisará implementar o código para calcular a curva PR para cada classificador.

Importante: *Você não pode usar funções de scikit-learn.metrics como classification_report, confusion_matrix, precision_recall_curve, etc.*

- 1) Siga as instruções no notebook de template fornecido para carregar os classificadores e os dados de teste.
- 2) Para cada classificador:
 - Calcular as predições (seguindo as instruções do notebook de template).
 - Calcular a matriz de confusão, a precisão e o recall para diferentes limiares (para isso, você terá que usar os rótulos verdadeiros do test set encontrados em y_test).
 - Produzir uma figura contendo uma curva PR para cada classificador. O gráfico resultante será semelhante ao exibido na Figura 2. O gráfico precisará ter uma legenda para identificar os diferentes classificadores (não é necessário fornecer a área sob a curva na legenda)
 - Calcular a área sob a curva PR (usando a função fornecida no notebook). Isso deve ser reportado na célula de código relevante no notebook fornecido.




Figura 3

- 3) Crie a mesma figura mencionada no ponto 2, mas agora utilize uma única chamada a uma função de plotagem. (Dica: use *pandas* e *seaborn* para isso; lembre-se de que no tutorial de *pandas* já se mostrou um jeito parecido.)

Parte 3 – Regressão - RMSE – valor desta seção: 20%
--

Baixe do repositório (<https://github.com/Mbaez97/fgv-class-2026-tarefa-1.git>)

- `linear_regression_model.p`
- `california_testing_data.p`

Os dados contêm informações do censo da Califórnia de 1990. Esses dados foram utilizados para treinar um sistema capaz de prever o valor mediano das casas em um determinado setor censitário.

O primeiro contém o modelo de regressão e o segundo o conjunto de dados de teste. O objetivo deste exercício é avaliar o desempenho do modelo de regressão pré-treinado na predição da mediana do valor do imóvel em um bloco.

O objetivo deste exercício é avaliar o desempenho do nosso modelo de regressão na predição de preços de casas calculando o Root Mean Squared Error (RMSE).

- 1) Siga as instruções no notebook de template fornecido para carregar os modelos e os dados de teste.
- 2) Para este exercício, você terá que calcular:
 - Os valores preditos para o conjunto de testes (seguindo as instruções no notebook)
 - O RMSE para o conjunto de testes.

O RMSE para o conjunto de testes deve ser calculado com código vetorizado. **O uso de loops resultará em 0 pontos nesta tarefa.**

Importante: você não pode usar funções pré-existentes como `sklearn.metrics.mean_squared_error`, você precisa escrever seu próprio código para calcular o erro)